Basit ve çoklu doğrusal regresyon

Diabetes veri setiyle karşılaştırmalı Python uygulaması

Amaç

Tek bir açıklayıcı değişken kullanan basit doğrusal regresyon ile birden fazla açıklayıcı değişken kullanan çoklu doğrusal regresyonu aynı eğitim ve test örneklerinde karşılaştırmak. Her iki modelin de çıktısı tek bir sayısal değerdir.

Veri seti

scikit-learn içindeki Diabetes veri setinde 442 kişinin 10 başlangıç özelliği ve bir yıl sonraki hastalık ilerleme puanı bulunur. Tahmin edilen hedef bu puandır; sınıf etiketi veya doğrudan kan şekeri değeri değildir. Eksik veri yoktur.

Özellik	Açıklama
age, sex	Yaş ve kodlanmış cinsiyet
bmi	Vücut kitle indeksi (BMI)
bp	Ortalama kan basıncı
s1–s6	Altı kan serumu ölçümü

İki model

Basit model: yalnız BMI kullanılır.
Tahmin = $b_0 + b_1 \times \text{BMI}$
Eğitimden elde edilen denklem: Tahmin = −131,8738 + 10,7628 × BMI.

Çoklu model: age, sex, bmi, bp, s1, s2, s3, s4, s5 ve s6 birlikte kullanılır.
Tahmin = $b_0 + b_1x_1 + \ldots + b_{10}x_{10}$. Katsayıların tamamı katsayilar.csv dosyasındadır.

Deney düzeni

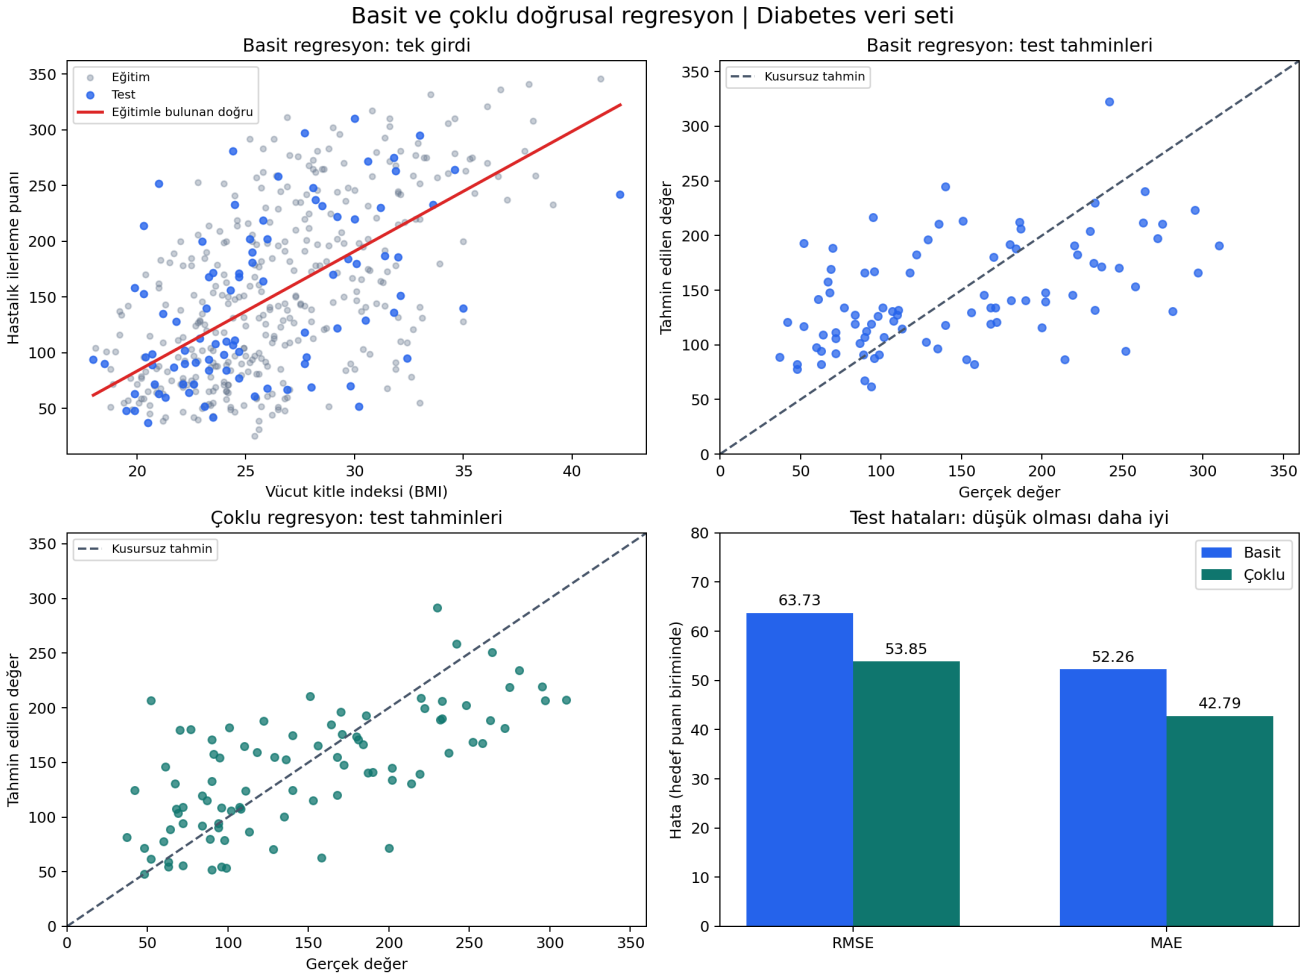
Veri %80 eğitim (353 kişi), %20 test (89 kişi) olarak ayrıldı. random_state=42 ile aynı ayrım tekrarlanabilir. İki model aynı satırları kullanır; katsayılar yalnız eğitim verisinden öğrenilir. sample_id ve split sütunları modele verilmez. BMI test sonuçlarına bakılarak seçilmemiştir.

load_diabetes(scaled=False) ile ham özellikler alındı. Bu örnekte standartlaştırma yapılmadı. LinearRegression, en küçük kareler çözümünü hesaplar; epoch veya öğrenme hızı ayarlanmaz. Basit/çoklu regresyon, ağdaki katman sayısını ifade etmez.

Sonuçlar ve grafikler

Model / bölüm	MSE	RMSE	MAE	R^2
Basit / Eğitim	3854,11	62,08	51,38	0,3657
Basit / Test	4061,83	63,73	52,26	0,2334
Çoklu / Eğitim	2868,55	53,56	43,48	0,5279
Çoklu / Test	2900,19	53,85	42,79	0,4526

Test RMSE değeri 63,73'ten 53,85'e düştü: yaklaşık %15,50 azalma. MAE de 52,26'dan 42,79'a düştü. Bu test bölünmesinde çoklu regresyon daha düşük hata üretti. RMSE ve MAE hastalık ilerleme puanı birimindedir.



Üst solda BMI ile hedef ve eğitim verisinden öğrenilen doğru görülür. Üst sağ ve alt solda test tahminleri yer alır; kesikli köşegen kusursuz tahmini gösterir. Alt sağda test RMSE ve MAE değerleri karşılaştırılır.

Eğitim ve test RMSE değerleri birbirine yakın olsa da bu tek ayrım, modelin her yeni veride aynı başarıyı göstereceğini kanıtlamaz. Hatalar sıfır değildir; özellikle yüksek hedef değerlerinde bazı tahminler gerçek değerin altında kalmaktadır.

Hatalar nasıl yorumlanır?

Kullanılan ölçütler

MSE — ortalama karesel hata: mean((gerçek − tahmin)²). Büyük hatalara daha fazla ağırlık verir. Hedef puanının karesi birimindedir; düşük olması daha iyidir.

RMSE — kök ortalama karesel hata: √MSE. Hedef değişkenle aynı birimdedir. Çoklu modelin test RMSE değeri 53,85 puandır; bu, hataların kareli ortalamasının kareköküdür, ortalama mutlak hata değildir.

MAE — ortalama mutlak hata: mean(|gerçek − tahmin|). Çoklu model test örneklerinde ortalama 42,79 puanlık mutlak hata yapmıştır.

R^2 — belirleme katsayısı: 1 − Σ(gerçek − tahmin)² / Σ(gerçek − test hedef ortalaması)². Çoklu modelde 0,4526, basit modelde 0,2334 bulunmuştur. R^2 yüzde doğruluk değildir; negatif de olabilir.

Kısa değerlendirme

Bu deneyde diğer özelliklerin de modele eklenmesi test hatasını azalttı. Ancak daha fazla özellik her zaman daha iyi sonuç vermez. Sonuçlar tek bir eğitim/test ayrımına aittir; farklı ayrımlarda değişebilir. Katsayılar değişkenler arasındaki ilişkileri temsil eder, nedensel etki kanıtlamaz.

Kodun çalıştırılması

Python 3.11 veya daha yeni bir sürümde, dosyaların bulunduğu dizinde:
pip install -r requirements.txt
python regresyon.py

Google Colab veya Jupyter için regresyon_odevi.ipynb dosyasını açıp hücreleri sırayla çalıştır. Notebook veri setini kendi yükler ve sonuçları çalışma dizinine kaydeder. Python dosyası sonuçları kendi bulunduğu dizine kaydeder.

Dosyalar: regresyon.py (uygulama), regresyon_odevi.ipynb (açıklamalı notebook), diabetes_veri_seti.csv (veri ve ayrım), sonuclar.csv (hata ölçümleri), test_tahminleri.csv (gerçek ve tahmin), katsayilar.csv (denklem katsayıları), regresyon_grafikleri.png (grafikler), README.md (açıklama).

Kaynaklar

scikit-learn — Diabetes dataset:
https://scikit-learn.org/stable/datasets/toy_dataset.html#diabetes-dataset

Özgün veri sayfası:
https://www4.stat.ncsu.edu/~boos/var.select/diabetes.html

Efron, B., Hastie, T., Johnstone, I. ve Tibshirani, R. (2004). Least Angle Regression. Annals of Statistics, 32(2), 407–499.